

一页结论

系统：把 184 份一手材料（A 股内存产业链年报/半年报、SEC 10-K、三星与 SK 海力士 IR、BIS 规则原文与 CFR 条文）切成 81,895 块，建「BM25 + 稠密向量」双通道索引，检索后交模型作答，**每条论断强制带 [n] 回原文**。语料抽取 184/184 份零失败，向量 $81,895 \times 1024$ 。

184 份里含 **44 对巨潮/交易所字节相同的重复**，**唯一文档实为 140 份**（见文末边界）。下文「184」一律指语料记录数。

结果：6/10，不是 10/10

先说这个数怎么来的，因为它比数本身重要。

第一版 10 道题「全过」。那个 **10/10 是假的**。判据当时是 HBM、2024、营业 这类词——一查词频就露馅：它们在库里分别出现 **538 / 20,831 / 6,269** 次，**任何一块都能让判据通过**。所以「全过」实际测的是「**程序没崩**」。戳破它的是一张页面截图：第 4 题（口径题）被**诚实地答成「材料未覆盖」**，而该题的判据照样判「过」——**判据和事实当场打架**。

改成「字面判据 + 结构判据」（跨几家公司 / 必须含哪个库 / 不得含哪个库）后，是 7/10。但 **7 也是虚的**。2026-10-04 逐题复核，发现两道题的判据**不回答问题也能通过**：

- **第 2 题**写明 `require_company=['美光']`，可 `judge()` **从来没读这个键**（当时的结构判据只实现了三条）。判据实际只剩 HBM（库里 538 块），而该题的 8 个席里**美光只占 1 席**。这是「**声明了却没接线的开关**」——和一个从不执行的判据同罪。
- **第 7 题**（全景）判的是「**跨 ≥ 3 家公司**」。它数的是**任意三家**，**不是问的那三家**：实得 14 席 = 佰维存储 $\times 7$ 、美光 $\times 5$ 、东芯股份 $\times 1$ 、SK 海力士 $\times 1$ ——**三星一块都没有**，判据却数出四家公司、照样通过。而模型自己的答案写着「三星的表述材料完全未覆盖」。

补上「**点名公司须出现，且出现在切题的块里**」「**指定公司占席下限**」两条结构判据后，真数是 **6/10**。

这里最该记的不是 6、7 还是 10，而是：**一个永远通过的判据，和一个不存在的判据一样没用，但更危险——它给人已经测过的错觉**。每写一条判据，都要拿它反问一句：**不回答这个问题，是不是也能通过？** 第 2、7 题就是漏问了这一句。

通过的六题

- **第 1 题·管制门槛** (B)。`greater than 2 gigabytes per second per square millimeter` 这句原文在 BM25 排第 **140**、稠密通道排第 **6,729**，两路都够不着；靠查询改写把它捞进前 8。
- **第 3 题·版本陷阱** (B)。能说清是 2024-12 那份 (89 FR 96790) 改了管制，不是另一份。
- **第 5 题·多主题** (A+B)。
- **第 6 题·长口语铺垫** (A+B)。问句在最后一句，检索没被前面的铺垫带偏。
- **第 9 题·跨库时间线** (A+B)。规则时点与厂商 ASP **两边都召回到了**——7 条 BIS 规则 + 3 条三星 ASP ("Memory-product ASP rose by approximately 60%")。模型据此如实回答「**对不上**」：两者口径不匹配，材料里也没有把二者联系起来的表述。**这是本题要考的「跨库」能力，答「对不上」是正确结论，不是翻车**（前一版记录误判为「库里一条财报都没有」，已更正）。
- **第 10 题·必败题** (诚实)。HBM3E 合约价在付费墙后。**给出任何数字都算错，哪怕碰巧对**；它承认了「材料未覆盖」。

没过的四题，各有一个可复现的根因

题目	现象	根因
Q2 美光 HBM 表述	美光只占 1/8 席	问的是美光一家，召回却被 SK 海力士（6 席）/ 三星（1 席）占满——跨公司题里的「大厂霸榜」。
Q4 口径题	召不回营业总收入	该块存在（江波龙合并利润表，BM25 第 39 名），但融合后进不了前 8；稠密通道对它更差——直接问「江波龙 合并利润表 营业总收入」时 BM25 排第 0、稠密仍在 100 名之外。字面通道找得到、语义通道找不到。
Q7 全景题	三星缺席	14 席里三星 0 条，原因同 Q2：大公司、大文件霸榜。DOC_CAP 限的是「同一份文件 3 块」，限不住「同一家公司多份文件」。
Q8 A 股披露	混进 BIS 规则文本	问的是「公司怎么披露」，14 条里混入 fedreg / govinfo——答成了「管制是什么」，不是「公司怎么说」。forbid_lib=B 判得住，但拦不住召回本身。

归纳：系统的失败模式是「够不着」，不是「编造」。两道够不着的题（Q4、Q10）都如实说了「材料未覆盖」——Q10 是故意设计的必败题。

三个设计是被实测逼出来的，不是先验的

1. 查询改写——条文里没有「门槛」这个词，它写的是 memory bandwidth density。用户问的是抽象概括，条文用的是具体物理量，检索系统该替用户做这一步转换。注意：这不是中英翻译问题（问「HBM 的内存带宽密度阈值」时稠密排第 6），是抽象层级问题。
2. 同文档限 3 块——第 1 题原本前 8 里有 5 块来自同一份《联邦公报》，把定义块挤到 24 名外。改成限席不动任何权重就解决了。调权重治不了（提到 1.0 只挪到 20 名）：席位被占满，谁也别想挤进去。
3. 判据分字面 / 结构两类，且结构判据必须「切题」——见上。只判「跨 N 家公司」不够，得判「是问的那几家、且出现在切题的块里」。

两个负结果也记下来：① 以为 Q8/Q9 的病根是「一个库霸榜」，试了按来源 / 按库限席。实测每来源 ≤5 修好 Q9 却弄坏 Q3，每库 ≤6 掉到 5/10——是拿一个失败换另一个，不可采纳（与「限文档」不同：限 1/2/3 都全过，那是机制）。② 查询改写并非逐字可复现：同一份代码连跑两次，第 7 题一次判过、一次判不过，查下来两次改写出的查询不一样（尽管 temperature=0）。已把「问题 → 改写查询」缓存到 knowledge_base/expand_cache.json，让交付的评价可复现。

边界（必须写明，不能糊过去）

- 表格拍平有已确认的错位：江波龙合并利润表里 一、营业总收入 10,195,655,370.19 是对的，但下一行 二、营业总成本 的数值被盖上了「利息收入」的标签。可测指纹命中财报类块的 61.2%——但这是标志率，不是确认的错误率，我只手核确认了一例。修复要重跑抽取并整库重嵌向量，记为已知缺陷。引财报数字前须回原 PDF 核对。
- section 字段会标错：第 9 题召回到的三星块，正文是「B. Changes in average selling price / Memory-product ASP...」，section 却写成 VI. Outstanding shares（股本表）。作业要求「切块带公司、章节、页码」——公司 100%、页码 100%，章节名会张冠李戴，引用前要核正文。
- 价格一手口径不可得：一手合约价在付费墙后，论文只写边界，不自己拼价格数。
- 台湾两家未纳入（证书链问题，不关 TLS 校验），全景题只覆盖三家。

一句话：这套系统能把英文管制条文里的**具体参数**、中文财报里的**具体表述**，连同出处一起端到用户面前，**跨库题（第 9 题）也真的跨成了**，并且在**够不着时承认够不着**；它现在的主要短板不是「胡说」，而是**几条召回不到的路**——跨公司霸榜（Q2/Q7）、口径题（Q4）、库边界（Q8），都已定位到可复现的原因，未修。**判分这件事本身也栽过两次跟头（10/10→7/10→6/10），每一次都是判据太弱**；这条教训和系统缺陷一样要紧。

配套： `十道题-检索记录.md`（逐题召回、改写查询、来源构成）、`管制侧引注表.md`（论文脚注）。